


云社区 > 云博客 > 博客详情
云社区 > 云博客 > 博客详情

机器学习|朴素贝叶斯 (Naive Bayes) 算法总结

 寻水的鱼 发表于 2018-01-31 10:34:02 01-31 10:34

 数据算法的鱼 发表于 2018-01-31 10:34:02 01-31 10:34


585 2 1

【摘要】 1. 简单定义朴素贝叶斯是一种简单快速的有监督学习方法。那么如何解读上面这句定义？从描述定义的词汇入手。类是一种确定数据类别的问题，例如天气阴晴，花开花谢，目标是将具有相似或相同特征的对象聚集。而线性分类（器）性组合来坐出分类决定。也就是说不同类别之间的分类边界图。线性算法的优点是训练和预测的效率比较高，但最终效

简单定义
朴素贝叶斯是一种简单快速的有监督学习类线性分类算法。

那么如何解读上面这句定义？从描述定义的词汇入手。

线性分类：分类是一种确定数据类别的问题，例如天气阴晴，花开花谢，水果酸甜等。其的对象聚集。而线性分类（器）透过特征的线性组合来坐出分类决定。也就是说不同类别之图。




线性算法的优点是训练和预测的效率比较高，但最终效果对特征的依赖程度较高，需要数据

有监督学习：监督学习是指用已经标记好的数据，做训练来预测新数据的类型，或者是值测一个值叫做回归。与无监督学习最简单的区分方法就是看训练样本数据有无标签，有即习。

朴素：假设某个特征的出现与其它特征的出现是独立的。举个例子：想要根据颜色、形状橙色、球形、味道酸甜的水果很可能是橘子。上述描述中，即使这些特征依赖于彼此或取决特性均可以单独地提升该果实是橘子的可能性，这就是为什么它被称为朴素。

贝叶斯定理：直白的说，贝叶斯定理实际描述用于计算条件概率的方法和公式。最简单的在事件B发生的情况下，另一事件A发生的概率，数学形式为P(A|B)。更直观的解释可借用下



在事件B发生的情况下，事件A发生的概率为：

$$P(A|B)=\frac{P(A\cap B)}{P(B)}$$


则：

$$\begin{aligned} P(A\cap B)&=P(A|B)P(B) \\ P(A\cap B)&=P(B|A)P(A) \end{aligned}$$

得到的条件概率计算公式为，

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

此时需要对P(B)做一个引申，即需要知道事件B的全概率。则推广上述的场景至更广义一些。事件A与A'的和，如图：



引入事件B后，事件B可划分为两个部分，1) 与事件A重合的部分；2) 与事件A'重合的部分。

$$P(B) = P(B \cap A) + P(B \cap A')$$


由上页的推导可得出：

$$P(B) = P(B|A)P(A) + P(B|A')P(A')$$

上述公式即为全概率公式。它的含义是，如果A和A'构成样本空间的一个划分，那么事件B的概率等于B对这两个事件的条件概率的和。将这个公式代入上一节的条件概率公式，就得到了：

$$P(A|B) = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|A')P(A')}$$

为了更直观的理解，在此举一个例子：



两个一模一样的碗，一号碗有30颗水果糖和10颗巧克力糖，二号碗有水果糖和巧克力糖各20颗。中摸出一颗糖，发现是水果糖。请问这颗水果糖来自一号碗的概率有多大？

我们假定， W_1 表示一号碗， W_2 表示二号碗。由于这两个碗是一样的，所以 $P(W_1) = P(W_2)$ 。前，这两个碗被选中的概率相同。因此， $P(W_1) = 0.5$ ，没有做实验之前，来自一号碗的概率是0.5。再假定，T表示水果糖，所以问题就变成了在已知T的情况下，来自一号碗的概率有多大，即

$$P(W_1|T) = \frac{P(T|W_1)P(W_1)}{P(T)}$$

已知， $P(W_1)$ 等于0.5， $P(T|W_1)$ 为一号碗中取出水果糖的概率，等于0.75，那么求出 $P(T)$ 就得到了：

$$P(T) = P(T|W_1)P(W_1) + P(T|W_2)P(W_2) = 0.75 \times 0.5 + 0.5 \times 0.5 = 0.625$$

$$P(W_1|T) = 0.5 \times \frac{0.75}{0.625}$$

上述解释只是针对空间内总样本数为2的情况，一般在机器学习中对训练样本和测试样本的分类，就是把标签为0和1的样本分别取出，建立两种训练模型 $model_0$ 和 $model_1$ 。在判别时分别代入 $model_0$ 和 $model_1$ ，选取拟合更好的模型。因此再推广朴素贝叶斯的公式至二分类：

$$P(y|(x_1, x_2, \dots, x_n)) = \frac{P((x_1, x_2, \dots, x_n)|y)P(y)}{P(x_1, x_2, \dots, x_n)}$$

由全概率公式可知：

华为云社区

则：

$$P(y|(x_1, x_2, \dots, x_n)) = \frac{P((x_1, x_2, \dots, x_n)|y=1)P(y=1)}{P((x_1, x_2, \dots, x_n)|y=1)P(y=1) + P((x_1, x_2, \dots, x_n)|y=0)P(y=0)}$$

根据朴素贝叶斯性质得知，若 x_1, x_2, \dots, x_n 之间相互独立，则有：

$$P((x_1, x_2, \dots, x_n)|y=1) = \prod_{i=1}^n P(x_i|y=1)$$

(举个例子便于理解，在下雨天时小明穿板鞋的概率是0.9，下雨天时小明吃米饭的概率为(吃米饭的概率为 $0.5 \times 0.9 = 0.45$ 。)

代入上页公式可得：

$$P((x_1, x_2, \dots, x_n)|y=1) = \frac{P(y=1) \prod_{i=1}^n P(x_i|y=1)}{P(y=1) \prod_{i=1}^n P(x_i|y=1) + P(y=0) \prod_{i=1}^n P(x_i|y=0)}$$

$P(x_i|y=1)$ 表示所有的标签为1的样本中， $x_i=1$ 的样本所占的比率， $P(x_i|y=0)$ 表示所有标签为0的样本中， $x_i=1$ 的样本所占的比率。那么如何得知 $P(y=1)$ 和 $P(y=0)$ 呢？其实很容易理解， $P(y=1)$ 是训练样本中标签为1的样本比率， $P(y=0)$ 是训练样本中标签为0的样本比率，在样本空间中找到标签为1的样本与总样本数m的比值即为 $P(y=1)$ ，同理可得 $P(y=0)$ 。

解释说明与分析

逻辑解释

$$P(y|(x_1, x_2, \dots, x_n)) = \frac{P((x_1, x_2, \dots, x_n)|y=1)P(y=1)}{P((x_1, x_2, \dots, x_n)|y=1)P(y=1) + P((x_1, x_2, \dots, x_n)|y=0)P(y=0)}$$

在二分类一般形式的朴素贝叶斯公式中，可以将等式右边分为 $P(y=1)$ 和 $\frac{P(x_1, x_2, \dots, x_n|y=1)}{P(x_1, x_2, \dots, x_n)}$ 的乘积，我们将 $P(y=1)$ 称为先验概率；

$$\frac{P(x_1, x_2, \dots, x_n|y=1)}{P(x_1, x_2, \dots, x_n)}$$

称为可能性函数，即调整因子；而等式左边的

$$P(y=1|x_1, x_2, \dots, x_n)$$

称为后验概率。那么公式就可以理解为：

$$\text{后验概率} = \text{先验概率} \times \text{调整因子}$$

这就是贝叶斯推断的含义。我们先预估一个"先验概率"，然后加入实验结果，看这个实验结果是否支持我们的"先验概率"，由此得到更接近事实的"后验概率"。在这里，如果调整因子

$$\frac{P(x_1, x_2, \dots, x_n|y=1)}{P(x_1, x_2, \dots, x_n)} > 1$$

意味着"先验概率"被增强，事件A的发生的可能性变大；如果调整因子 $=1$ ，意味着B事件无影响；如果调整因子 <1 ，意味着"先验概率"被削弱，事件A的可能性变小。在某种意义上讲，这个公式

普适推广至多分类下的朴素贝叶斯

在更多的情况下，样本的分类情况远远多于二分，标签的数量不只是2。那么一般化多分类的

$$P(y_j|x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n|y_j)P(y_j)}{P(x_1, x_2, \dots, x_n)}$$

我们可定义 v_{MAP} 为最大后验值， $\arg \max$ 函数定义为求出使目标函数取得最大值对应的

$$v_{MAP} = \arg \max_{y_j \in Y} P(y_j|x_1, x_2, \dots, x_n)$$

由于 x_1, x_2, \dots, x_n 之间相互独立，则有：

由于 $P(x_1, x_2, \dots, x_n)$ 给定输入为常数，则有：

$$v_{MAP} \propto P(y_j) \prod_{i=1}^n P(x_i|y_j)$$

实际上，上式右边就是朴素贝叶斯分类器公式：

$$v_{NB} = \arg \max_{y_j \in Y} P(y_j) \prod_{i=1}^n P(x_i|y_j)$$

朴素贝叶斯优缺点

优点：

这是一个相对容易构建和理解的算法。

使用该算法比许多其他分类算法能更快地预测类。

使用小数据集也可以容易地训练数据。

类条件特征独立分布意味着每个类分布可以独立地估计为一维分布。这又有助于缓解数据降

缺点：

如果给定没有出现过的类和特征，则该类别的条件概率估计将出现0，该问题被称为“零条件”因为它会擦除其他概率中的所有信息。

另一个缺点是它的特征之间独立的假设非常强。在现实生活中几乎很难找到这样的数据集。

间相关性较大时，朴素贝叶斯分类模型的分类效率低。而在属性相关性较小时，朴素贝叶斯

改进

拉普拉斯平滑

拉普拉斯平滑是为了解决上述“零条件概率问题”。考虑一种特殊情况，如果样本中变量 x_i 的取

式子 $\prod_{i=1}^n P(x_i|y_j)$ 的结果也为0，显然不合理。因此需要对0概率进行调整。对于此问题，滑法，以基础的二分类为例：

$$\begin{aligned} P(x_i|y=1) &= \frac{1 + \sum_{i=1}^m I(x_j^{(i)} = 1, y^{(i)} = 1)}{1 + \sum_{i=1}^m I(x_j^{(i)} = 1, y^{(i)} = 1) + 1 + \sum_{i=1}^m I(x_j^{(i)} = 0, y^{(i)} = 1)} \\ &= \frac{1 + \sum_{i=1}^m I(x_j^{(i)} = 1, y^{(i)} = 1)}{2 + \sum_{i=1}^m I(y^{(i)} = 1)} \end{aligned}$$

更一般情况下，加入 x_i 有 k 个不同的取值，当样本数量足够大时加入拉普拉斯平滑后并不会影

$$P(x_i|y = k_i) = \frac{1 + \sum_{i=1}^m I(x_j^{(i)} = k_i, y^{(i)} = 1)}{k + \sum_{i=1}^m I(y^{(i)} = 1)}$$

作者|王天鸿

【版权声明】本文为华为云社区用户转载文章，如果您发现本的内容，欢迎发送邮件至：huaweicloud.bbs@huawei.com 进关证据，一经查实，本社区将立刻删除涉嫌侵权内容。

数据算法

机器学习

展开全部内容

评论文章

(1)

(0)

上一篇：如何成为一名优秀的JA...

下一篇：中国